



北京交通大学

# 图像处理与机器学习

Digital Image Processing and Machine Learning

主讲人：黄琳琳

电子信息工程学院



# 基本概念

➤ 举例：手写字符识别（Handwritten Character Recognition）



$$y_k(\vec{x}) = y_k(\vec{x}, \vec{w}) \quad \text{贝叶斯决策}$$

$$y_k(\vec{x}) = p(\omega_k | \vec{x})$$

?



## 第五章 贝叶斯决策

- ◆ 基本概念
- ◆ 贝叶斯决策
- ◆ 判别函数
- ◆ 概率密度估计



# 判别函数

◆ 判别函数  $y_k(\vec{x}) = p(\omega_k | \vec{x})$

$$y_k(\vec{x}) = p(\vec{x} | \omega_k) p(\omega_k) \quad y_k(\vec{x}) = -R(\alpha_i | \vec{x})$$

- ✓ 先验概率密度估计
- ✓ 类条件概率密度估计

如何估计概率密度？



# 判别函数

- ✓ 先验概率密度估计
  - 从训练样本估计或者假设
- ✓ 类条件概率密度估计
  - 参数法 (parametric)
  - 非参数法 (Non-parametric)
  - 半参数法 (Semi-parametric)



# 判别函数

## ◆ 参数法

- ✓ 假定概率密度函数形式，估计函数中的参数

$$p(\vec{x} | \omega_i) = p(\vec{x} | \theta_i) \quad \textit{Gaussian, Gamma, Bernouli}$$

- ✓ 参数估计的方法

- 极大似然估计 (Maximum-Likelihood Estimation, ML)

- 贝叶斯估计 (Bayesian Estimation, BE)



# 概率密度估计

## ◆ 极大似然估计 (Maximum Likelihood estimation, ML)

- 假设已知概率密度函数形式  $p(\omega|\vec{x}, \theta)$  , 需要估计其中的参数  $\theta$
- 设  $\vec{x}_1, \dots, \vec{x}_n$  为数据集D中 随机抽取的  $n$  个相互独立的样本。

$$p(D|\theta) = p(\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n | \theta) \quad p(D|\theta) = \prod_{j=1}^n p(\vec{x}_j | \theta)$$

$p(D|\theta)$  为待估计参数  $\theta$  的似然函数

极大似然估计: 寻求  $\theta$  估计值  $\hat{\theta}$  , 使得似然函数最大



# 概率密度估计

## ◆ 极大似然估计 ( Maximum likelihood estimation )

$$\text{Maximize } p(D | \theta) \quad p(D | \theta) = \prod_{j=1}^n p(\vec{x}_j | \theta)$$

$$l(\theta) \equiv \ln p(D | \theta) \quad l(\theta) = \sum_{j=1}^n \ln p(\vec{x}_j | \theta)$$

$$\text{Maximize } l(\theta) \quad \nabla_{\theta} l(\theta) = 0$$

$$\nabla_{\theta} l(\theta) = \sum_{j=1}^n \nabla_{\theta} \ln p(\vec{x}_j | \theta) = 0$$

↓  
 $\hat{\theta}$





# 概率密度估计

## ◆ ML算法举例：高斯分布情况（The Gaussian case）

-- 已知概率密度函数为高斯分布，估计均值  $\vec{\mu}$  和方差  $\Sigma$

$$p(\vec{x} | \vec{\mu}) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp\left[-\frac{1}{2} (\vec{x} - \vec{\mu})^t \Sigma^{-1} (\vec{x} - \vec{\mu})\right]$$

以一维为例，估计  $\mu$  和方差  $\sigma^2$

$$\theta_1 = \mu, \quad \theta_2 = \sigma^2 \quad \vec{\theta} = (\theta_1, \theta_2)$$

$$l(\vec{\theta}) = \ln p(x | \vec{\theta}) = -\frac{1}{2} \ln 2\pi\theta_2 - \frac{1}{2\theta_2} (x - \theta_1)^2$$



# 概率密度估计

$$l(\vec{\theta}) = \ln p(x | \vec{\theta}) = -\frac{1}{2} \ln 2\pi\theta_2 - \frac{1}{2\theta_2} (x - \theta_1)^2$$

$$\nabla_{\theta} l(\theta) = \sum_{j=1}^n \nabla_{\theta} \ln p(\vec{x}_j | \theta) = 0$$

$$\nabla_{\vec{\theta}} [\ln p(\vec{x} | \vec{\theta})] = \begin{pmatrix} \frac{1}{\theta_2} (\vec{x} - \theta_1) \\ -\frac{1}{2\theta_2} + \frac{(\vec{x} - \theta_1)^2}{2\theta_2^2} \end{pmatrix} = 0$$

$$\hat{\mu} = \frac{1}{n} \sum_{k=1}^n x_k$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{k=1}^n (x_k - \hat{\mu})^2$$

推广到高维，可得：

$$\hat{\vec{\mu}} = \frac{1}{n} \sum_{j=1}^n \vec{x}_j$$

$$\hat{\Sigma} = \frac{1}{n} \sum_{k=1}^n (x_k - \hat{\vec{\mu}})(x_k - \hat{\vec{\mu}})^t$$



# 概率密度估计

## ◆ 贝叶斯估计 ( Bayesian estimation )

- 假设参数的条件概率密度  $p(\vec{x}|\bar{\theta})$  和 先验概率  $p(\bar{\theta})$  已知
- 将参数视为随机变量, 估计参数的后验概率

$$p(\omega_k | \vec{x}) = p(\vec{x} | \omega_k) p(\omega_k)$$

同一类的样本集  $D$       $p(\vec{x} | D) = \int p(\vec{x}, \theta | D) d\theta$

$$p(\vec{x}, \theta | D) = p(\vec{x} | \theta) \cdot p(\theta | D)$$



# 概率密度估计

## ◆ 贝叶斯估计 ( Bayesian estimation )

-- 假设参数的条件概率密度  $p(\vec{x}|\bar{\theta})$  和 先验概率  $p(\bar{\theta})$  已知

同一类的样本集  $D$

$$p(\vec{x}, \theta | D) = p(\vec{x} | \theta) p(\theta | D)$$

$$p(\theta | D) = \frac{p(D | \theta) p(\theta)}{\int p(D | \theta) p(\theta) d\theta}$$

$$p(D | \theta) = \prod_{k=1}^n p(x_k | \theta)$$

$$p(\vec{x} | D) = \int p(\vec{x}, \theta | D) d\theta$$

$$p(\vec{x} | \omega_k)$$



# 谢 谢

本课程所引用的一些素材为主讲老师多年的教学积累，来源于多种媒体及同事和同行的交流，难以一一注明出处，特此说明并表示感谢！