



北京交通大学

图像处理与机器学习

Digital Image Processing and Machine Learning

主讲人：黄琳琳

电子信息工程学院



概率密度估计

◆ 非参数法 (Non-parametric)

-- 可以估计任意概率密度函数

- Parzen window
- K-Nearest Neighbor



概率密度估计

◆ 概率

-- 特征空间中一定区域内样本的比率

假设 N 个样本之中的 k 个 落入特征矢量 x 的周边局部区域 R , 则概率为: $P = \frac{k}{N}$

◆ 概率密度 $p(x)$

-- 假设局部区域 R (体积为 V , 样本数为 k) 内等概率密度

$$P = \int_R p(x') dx' \approx p(x) \cdot V \quad P = \frac{k}{N} \quad \longrightarrow \quad p(x) \approx \frac{k}{N \cdot V}$$

如何估计概率密度 $p(x)$?



概率密度估计

$$p(x) \approx \frac{k}{N \cdot V}$$

◆ 两种估计方法:

-- 固定局部区域体积 V 大小, 参数 k 变化

Parzen Window

-- 固定参数 k 值, 局部区域体积 V 变化

K -nearest Neighbor




概率密度估计

➤ Parzen Window

- 设样本点 x 周边是一个边长为 h 的超立方体 (hypercube)
- 局部区域体积 V 为 d -维空间: $V = h^d$
- 单位超立方体 (unit hypercube), 称为窗函数

$$\varphi(\vec{u}) = \begin{cases} 1, & |u_j| < 1/2, j = 1, 2, \dots, d \\ 0, & \text{else} \end{cases}$$

$$\vec{u} = (u_1, u_2, \dots, u_d)^T$$





概率密度估计

➤ Parzen Window


-- 训练数据集 $D: \{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_N\}$

-- 边长为 h 的立方体的体积: $V = h^d$

-- 落入立方体的点数 k :

$$k = \sum_{n=1}^N \varphi\left(\frac{\vec{x} - \vec{x}_n}{h}\right)$$

$$-\frac{1}{2} < \frac{\vec{x} - \vec{x}_n}{h} < \frac{1}{2}$$



$$\varphi(\vec{u}) = \begin{cases} 1, & |u_k| < 1/2, k = 1, 2, \dots, d \\ 0, & \text{else} \end{cases}$$



概率密度估计

➤ Parzen Window

$$p(x) \approx \frac{k}{N \cdot V} \quad D: \{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_N\}$$

$$k = \sum_{n=1}^N \varphi\left(\frac{\vec{x} - \vec{x}_n}{h}\right) \quad V = h^d$$

$$\hat{p}(x) = \frac{1}{N} \sum_{n=1}^N \frac{1}{h^d} \varphi\left(\frac{\vec{x} - \vec{x}_n}{h}\right)$$



概率密度估计

➤ Parzen Window

$$\varphi(\vec{u}) = \begin{cases} 1, & |u_j| < 1/2, j = 1, 2, \dots, d \\ 0, & \text{else} \end{cases}$$

矩形窗

$$\hat{p}(x) = \frac{1}{N} \sum_{n=1}^N \frac{1}{h^d} \varphi\left(\frac{\vec{x} - \vec{x}_n}{h}\right)$$

$$\varphi(\vec{u}) = \frac{1}{(2\pi)^{d/2}} \exp\left(-\frac{\|\vec{u}\|^2}{2}\right)$$

高斯函数（窗）

$$\hat{p}(x) = \frac{1}{N} \sum_{n=1}^N \frac{1}{(2\pi h^2)^{d/2}} \exp\left(-\frac{\|\vec{x} - \vec{x}_n\|^2}{2h^2}\right)$$



概率密度估计

◆ 分类的例子

$$p(x) \approx \frac{k}{N \cdot V} \quad D: \{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_N\}$$

第 i 类条件概率密度:


$$p(x | \omega_i) \approx \frac{k_i}{N_i \cdot V}$$

$$\max_i p(x | \omega_i) p(\omega_i)$$



概率密度估计


◆ 分类的例子 $p(x | \omega_j) \approx \frac{k_j}{N_j \cdot V}$ $\max_i p(x | \omega_i) p(\omega_i)$



Large h

Large h : low variability, under-fitting

Decision regions



Small h

Small h : high variability, over-fitting



概率密度估计

$$p(x) \approx \frac{k}{N \cdot V}$$

◆ 两种估计方法:

- 固定局部区域体积 V 大小, 参数 k 变化
- 固定参数 k 值, 局部区域体积 V 变化

K-nearest Neighbor



概率密度估计

◆ K 近邻 (K-nearest Neighbor)

-- 固定参数 k 值, 局部区域体积 V 变化

对于来自于 ω_i 的 N_i 个样本, 扩大(缩小)窗口使得有 k_i 个点落入该窗口.

第 i 类条件概率密度:
$$p(x | \omega_i) \approx \frac{k_i}{N_i \cdot V}$$



K 近邻

$$p(x | \omega_i) \approx \frac{k_i}{N_i \cdot V} \quad \sum_{i=1}^M k_i = k \quad p(\omega_i) = \frac{N_i}{N} \quad p(\omega_j) = \frac{N_j}{N}$$

贝叶斯公式

$$p(\omega_i | x) = \frac{p(x | \omega_i) p(\omega_i)}{\sum_j^M p(x | \omega_j) p(\omega_j)} = \frac{(k_i / N_i) \cdot p(\omega_i)}{\sum_j^M (k_j / N_j) \cdot p(\omega_j)} = \frac{k_i}{\sum_j^M k_j} = \frac{k_i}{k}$$

$$p(\omega_i | x) = \frac{k_i}{k}$$



K 近邻

$$p(x | \omega_i) \approx \frac{k_i}{N_i \cdot V} \quad \sum_{i=1}^M k_i = k \quad p(\omega_i) = \frac{N_i}{N} \quad p(\omega_j) = \frac{N_j}{N}$$

$$p(\omega_i | x) = \frac{k_i}{k}$$

贝叶斯决策：分到后验概率最大的类，分类错误率最小

To select the class with *most nearest neighbors* among *k* will make minimum-error decision.



K 近邻

假设有a、b、c三个样类别的样本，在随机变量X的10-近邻中有3个a类点，2个b类点，5个c类点，应该将该随机变量归为哪一类分类错误最小？为什么？

$$p(\omega_i | x) = \frac{k_i}{k}$$

$$p(\omega_a | x) = \frac{3}{10}$$

$$p(\omega_b | x) = \frac{2}{10}$$

$$p(\omega_c | x) = \frac{5}{10}$$

根据贝叶斯决策，将此随机变量X归为c类，分类错误最小。



谢 谢

本课程所引用的一些素材为主讲老师多年的教学积累，来源于多种媒体及同事和同行的交流，难以一一注明出处，特此说明并表示感谢！